Tarea 1

Universidad Nacional Autónoma de México
Aprendizaje de máquina
Baruch Mejía Martínez

I. Descripción

En los problemas de código, se dio una tabla que contienen en sus columnas un cierto número de atributos y un valo de clase a la que pertenece cada dato. El problema general consiste en poder hacer una clasificación sobre esos datos, pero eso nos supone algunos puntos a cubrir:

- Definir como se decidirá a que clase pertenece un conjunto de atributos.
- Que conjunto de datos es el ideal para tener un mejor desempeño del clasificador.
- Poder comparar el desempeño del clasificador propuesto (Clasificador Bayesiano Ingenuo) con algún otro clasificador (se usó un clasificador gaussiano).

II. Código

En testa tarea de clasificación para diferentes conjuntos de datos, parecía buena idea crear clases para diferentes módulos del proceso, tal que se pudiera generalizar el proceso para cada conjunto de datos, entonces se proponen las siguientes clases:

- ETL: clase para estandarizar los datos y hacer limpieza, dejandolos listos para el clasificador.
- CategoricalNB: es el clasificador bayesiano ingenuo.
- ClasificadoresPipeline: flujo general que recibe los conjuntos de datos limpios y separados del ETL instanciado para el conjunto de datos, y hace el flujo de entrenamiento y validación de ambos clasificadores

II-A. ETL

La clase ETL, se inicializa con la ruta a la tabla en formato csv, y al instanciarlo carga los datos en un dataFrame con la posibilidad de añadir un encabezado si se requiere. También hace una limpieza de los datos de la siguiente manera:

- Remueve columnas inecesarias para la clasificación, como los ids si se especifica.
- Convierte todos los datos a numéricos, tal que si existe algún valor no numérico lo hace nan
- Elimina registros que tengan valores nan en alguna parte.

Posteriormente se puede llamar al método publico get data, que requiere los porcentajes de datos para entrenamiento, validación y prueba, y lo que se hace por detrás, es que hace un muestreo estratificado con una semilla fija de pseudoaleatoriedad para cada conjunto de datos en sus porcentajes requeridos.

También se tienen un método que regresa un resumen sobre los datos, en cuanto a numero de características, numero de clases y porcentaje de cada clase en los datos totales.

II-B. ClasificadoresPipeline

Esta clase hace todo el flujo a partir de los datos obtenidos del ETL, pero compara el clasificador bayesiano ingenuo con un clasificador gausiano, tal que ambos se entrenan con los datos de entrenamiento, se hace una evaluación de ambos con los datos de validación y se muestran sus respectivos valores de accuracy y se decide cuál de los dos evaluó mejor a partir del accuracy.

Finalmente con el mejor clasificador, se evalúa con los datos de prueba y se muestra su matriz de confusión.

III. Resultados

III-A. Clasificación de Spam

Los datos entregados son de histogramas por palabra, dando un total de 2000 atributos, entre los cuales el 71 % son de correos que no son spam, y el restante 30 % son spam.

Se evaluaron dos clasificadores bayesianos ingenuos: CategoricalNB y GaussianNB. El desempeño se midió utilizando la exactitud, definida como la proporción de predicciones correctas respecto al total de ejemplos evaluados.

Clasificador	Exactitud
CategoricalNB	0.7339
GaussianNB	0.9342

Tabla I
Exactitud de los clasificadores en el conjunto de entrenamiento.

A continuación se muestra la matriz de confusión del clasificador bayesiano igenuo con los datos de entrenamiento:

$$\begin{bmatrix} 4406 & 0 \\ 1651 & 148 \end{bmatrix}$$

A continuación se muestra la matriz de confusión del clasificador gaussiano con los datos de entrenamiento:

$$\begin{bmatrix} 4393 & 13 \\ 395 & 1404 \end{bmatrix}$$

En cuanto a los datos de validación, se pidió la predicción con ambos modelos entrenados y se obtuvieron los siguientes valores de exactitud:

Clasificador	Exactitud
CategoricalNB	0.7351
GaussianNB	0.9222

Tabla II
EXACTITUD DE LOS CLASIFICADORES EN EL CONJUNTO DE VALIDACIÓN.

Y sus respectivas matrices de confusión para los datos de validación, primero para el CategoricalNB

$$\begin{bmatrix} 1469 & 0 \\ 548 & 52 \end{bmatrix}$$

ahora para el GaussianNB:

$$\begin{bmatrix} 1456 & 13 \\ 148 & 452 \end{bmatrix}$$

Los resultados muestran que el clasificador GaussianNB obtiene una exactitud considerablemente mayor que CategoricalNB tanto en entrenamiento como en validación. Además, las matrices de confusión indican que CategoricalNB tiende a clasificar la mayoría de los ejemplos en una sola clase, mientras que GaussianNB logra un desempeño más equilibrado entre ambas clases.

Dado que a GaussianNB le fue mejor en la validación, se pasó a usar este modelo para los datos de prueba, en el que se logró una exactitud de 0.9280, con la siguiente matriz de confusión:

$$\begin{bmatrix} 1455 & 14 \\ 135 & 465 \end{bmatrix}$$

III-B. Clasificación de Cáncer

Los datos entregados corresponden a una tabla con 9 atributos que describen características celulares utilizadas para determinar si un tumor es benigno o maligno. En el conjunto de datos, el 65,01 % de los casos corresponden a tumores benignos, mientras que el 34,99 % corresponden a tumores malignos.

Se evaluaron dos clasificadores bayesianos ingenuos: CategoricalNB y GaussianNB. El desempeño se midió utilizando la exactitud, definida como la proporción de predicciones correctas respecto al total de ejemplos evaluados.

```
#################################################
#           Resumen de datos cargados           #
#################################################

Cantidad de clases: 2
Cantidad de atributos: 2000
Proporción de clase 'No spam': 71.00%
Proporción de clase 'Spam': 29.00%
#################################################
Entrenando clasificadores...

Evaluación en entrenamiento:
CategoricalNB - Exactitud: 0.7339
Matriz de confusión:
[[4406    0]
 [1651  148]]
GaussianNB - Exactitud: 0.9342
Matriz de confusión:
[[4393   13]
 [ 395 1404]]

Evaluación en validación:
CategoricalNB - Exactitud: 0.7351
Matriz de confusión:
[[1469    0]
 [ 548   52]]
GaussianNB - Exactitud: 0.9222
Matriz de confusión:
[[1456   13]
 [ 148  452]]

Comparación de desempeño en validación:
GaussianNB tuvo mejor desempeño en validación.

Evaluación en prueba (mejor clasificador):
GaussianNB - Exactitud: 0.9280
Matriz de confusión:
[[1455   14]
 [ 135  465]]
```

Figura 1. Resultado en terminal del proceso de entrenamiento, validación y prueba en el conjunto de datos de correos spam.

Clasificador	Exactitud
CategoricalNB	0.9756
GaussianNB	0.9633

Tabla III
EXACTITUD DE LOS CLASIFICADORES EN EL CONJUNTO DE ENTRENAMIENTO.

A continuación se muestra la matriz de confusión del clasificador bayesiano ingenuo con los datos de entrenamiento:

$$\begin{bmatrix} 258 & 8 \\ 2 & 141 \end{bmatrix}$$

A continuación se muestra la matriz de confusión del clasificador gaussiano con los datos de entrenamiento:

$$\begin{bmatrix} 254 & 12 \\ 3 & 140 \end{bmatrix}$$

En cuanto a los datos de validación, se pidió la predicción con ambos modelos entrenados y se obtuvieron los siguientes valores de exactitud:

Clasificador	Exactitud
CategoricalNB	0.9854
GaussianNB	0.9708

Tabla IV
EXACTITUD DE LOS CLASIFICADORES EN EL CONJUNTO DE VALIDACIÓN.

Y sus respectivas matrices de confusión para los datos de validación, primero para el CategoricalNB

$$\begin{bmatrix} 88 & 1 \\ 1 & 47 \end{bmatrix}$$

ahora para el GaussianNB:

$$\begin{bmatrix} 86 & 3 \\ 1 & 47 \end{bmatrix}$$

Los resultados muestran que el clasificador CategoricalNB obtiene una exactitud ligeramente mayor que GaussianNB tanto en entrenamiento como en validación. Además, las matrices de confusión indican que ambos modelos logran identificar correctamente la mayoría de los casos, aunque CategoricalNB presenta un número ligeramente menor de errores de clasificación.

Dado que CategoricalNB obtuvo mejor desempeño en validación, se utilizó este modelo para evaluar el conjunto de prueba, en el que se logró una exactitud de 0.9708, con la siguiente matriz de confusión:

$$\begin{bmatrix} 85 & 4 \\ 0 & 48 \end{bmatrix}$$

III-C. Clasificación de Aves

Los datos entregados corresponden a un conjunto con 2 atributos utilizados para clasificar aves en dos clases. En el conjunto de datos ambas clases están balanceadas, con una proporción de 50 % para la clase 0 y 50 % para la clase 1.

Se evaluaron dos clasificadores bayesianos ingenuos: CategoricalNB y GaussianNB. El desempeño se midió utilizando la exactitud, definida como la proporción de predicciones correctas respecto al total de ejemplos evaluados.

Clasificador	Exactitud
CategoricalNB	0.8375
GaussianNB	0.8375

Tabla V
EXACTITUD DE LOS CLASIFICADORES EN EL CONJUNTO DE ENTRENAMIENTO.

```
##################################################
#           Resumen de datos cargados            #
##################################################

Cantidad de clases: 2
Cantidad de atributos: 9
Proporción de clase 'Benigno': 65.01%
Proporción de clase 'Maligno': 34.99%
##################################################
Entrenando clasificadores...

Evaluación en entrenamiento:
CategoricalNB - Exactitud: 0.9756
Matriz de confusión:
[[258   8]
 [  2 141]]
GaussianNB - Exactitud: 0.9633
Matriz de confusión:
[[254  12]
 [  3 140]]

Evaluación en validación:
CategoricalNB - Exactitud: 0.9854
Matriz de confusión:
[[88  1]
 [ 1 47]]
GaussianNB - Exactitud: 0.9708
Matriz de confusión:
[[86  3]
 [ 1 47]]

Comparación de desempeño en validación:
CategoricalNB tuvo mejor desempeño en validación.

Evaluación en prueba (mejor clasificador):
CategoricalNB - Exactitud: 0.9708
Matriz de confusión:
[[85  4]
 [ 0 48]]
```

Figura 2. Resultado en terminal del proceso de entrenamiento, validación y prueba en el conjunto de clasificación de tumores.

A continuación se muestra la matriz de confusión del clasificador bayesiano ingenuo con los datos de entrenamiento:

$$\begin{bmatrix} 508 & 92 \\ 103 & 497 \end{bmatrix}$$

A continuación se muestra la matriz de confusión del clasificador gaussiano con los datos de entrenamiento:

$$\begin{bmatrix} 508 & 92 \\ 103 & 497 \end{bmatrix}$$

En cuanto a los datos de validación, se pidió la predicción con ambos modelos entrenados y se obtuvieron los siguientes valores de exactitud:

Clasificador	Exactitud
CategoricalNB	0.8275
GaussianNB	0.8275

Tabla VI
EXACTITUD DE LOS CLASIFICADORES EN EL CONJUNTO DE VALIDACIÓN.

Y sus respectivas matrices de confusión para los datos de validación, primero para el CategoricalNB

$$\begin{bmatrix} 165 & 35 \\ 34 & 166 \end{bmatrix}$$

ahora para el GaussianNB:

$$\begin{bmatrix} 165 & 35 \\ 34 & 166 \end{bmatrix}$$

Los resultados muestran que ambos clasificadores obtienen exactamente el mismo desempeño tanto en entrenamiento como en validación. Además, las matrices de confusión son idénticas para ambos modelos, lo que indica que realizan las mismas predicciones sobre los datos evaluados.

Dado que ambos clasificadores obtuvieron el mismo desempeño en validación, se utilizó CategoricalNB para evaluar el conjunto de prueba, en el que se logró una exactitud de 0.8425, con la siguiente matriz de confusión:

$$\begin{bmatrix} 172 & 28 \\ 35 & 165 \end{bmatrix}$$

IV. ANÁLISIS DE RESULTADOS

En el conjunto de datos de correos electrónicos (spam), el clasificador GaussianNB obtuvo un desempeño superior al de CategoricalNB. Ya que los datos son histogramas de frecuencia de palabras, su comportamiento puede aproximarse a distribuciones continuas cuando el número de ocurrencias es suficientemente grande, lo que favorece el modelo gaussiano. Por otra parte, el CategoricalNB tiende a perder información al tratar los valores únicamente como categorías discretas, por lo que tuvo una menor capacidad para identificar correctamente los correos de spam.

En el conjunto de datos de cáncer, ambos clasificadores lograron un desempeño muy alto, aunque CategoricalNB obtuvo una ligera ventaja. En este caso, los atributos corresponden a valores discretos de características de celular o tumores, lo que se ajusta mejor al supuesto de variables categóricas. Entonces, el modelo categórico logró capturar la distribución de los datos y presentó menos errores de clasificación.

Finalmente, en el conjunto de datos de aves, ambos clasificadores produjeron exactamente los mismos resultados tanto en entrenamiento como en validación. Esto es curioso, entonces podría ser que para este

```
#################################################
#            Resumen de datos cargados          #
#################################################

Cantidad de clases: 2
Cantidad de atributos: 2
Proporción de clase 0: 50.00%
Proporción de clase 1: 50.00%
#################################################
Entrenando clasificadores...

Evaluación en entrenamiento:
CategoricalNB - Exactitud: 0.8375
Matriz de confusión:
[[508  92]
 [103 497]]
GaussianNB - Exactitud: 0.8375
Matriz de confusión:
[[508  92]
 [103 497]]

Evaluación en validación:
CategoricalNB - Exactitud: 0.8275
Matriz de confusión:
[[165  35]
 [ 34 166]]
GaussianNB - Exactitud: 0.8275
Matriz de confusión:
[[165  35]
 [ 34 166]]

Comparación de desempeño en validación:
Ambos clasificadores tuvieron el mismo desempeño e
 validación.

Evaluación en prueba (mejor clasificador):
CategoricalNB - Exactitud: 0.8425
Matriz de confusión:
[[172  28]
 [ 35 165]]
```

Figura 3. Resultado en terminal del proceso de entrenamiento, validación y prueba en el conjunto de datos de especies de aves.

conjunto de datos en particular, las fronteras de decisión aprendidas por ambos modelos son equivalentes. Ya que el problema cuenta únicamente con dos atributos y las clases están balanceadas, es posible que la separación entre clases sea simple y pueda ser capturada de manera similar por ambos enfoques probabilísticos, pero sinceramente no estoy seguro de por que salieron igual, solo apunto a que sí fue por tener datos balanceados de dos clases simples.

En general, los resultados muestran que el desempeño del clasificador bayesiano ingenuo depende en gran medida de qué tan bien se ajustan los supuestos de distribución del modelo a la naturaleza de los datos. Cuando los atributos se comportan de forma

aproximadamente continua, el modelo gaussiano tiende a obtener mejores resultados, mientras que cuando los atributos son discretos o categóricos, el modelo categórico puede resultar más adecuado.